08.12.2025

SAKARYA ÜNİVERSİTESİ

BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

VERİ MADENCİLİĞİ

MÜŞTERİ SEGMENTASYON PROJESİ

Prof.Dr.Nilüfer YURTAY

HAZIRLAYANLAR:

B221210566 SARA MOHAMED

B221210072 HALİME SELİN ŞAHİN

B221210044 BERAT ALPSAR

1.ÖZET

Günümüzün rekabetçi perakende ortamında, müşteri ilişkileri yönetimi (CRM) stratejilerinin başarısı, doğru pazar bölümlendirmesine ve kişiselleştirilmiş yaklaşımlara dayanmaktadır. Bu çalışmanın temel amacı, UCI Machine Learning Repository bünyesinde yer alan Online Retail II veri setini kullanarak, müşterileri satın alma alışkanlıklarına göre homojen gruplara ayırmaktır. Analiz sürecinde, müşterilerin işletme ile olan etkileşim düzeylerini belirleyen Toplam Harcama (Monetary) ve İşlem Sıklığı (Frequency) değişkenleri temel alınmıştır.

Veri setindeki yapısal desenleri ve doğal grupları ortaya çıkarmak amacıyla, veriyi detaylı bir ağaç yapısı ile inceleyen Hiyerarşik Kümeleme (Agglomerative Clustering) yöntemi uygulanmıştır. Oluşturulan dendrogram üzerindeki kırılımlar analiz edilerek müşteriler; "En Değerli", "Sadık" ve "Yeni/Düşük Profilli" olmak üzere üç ana stratejik segmente ayrılmıştır. Analiz sonucunda elde edilen bu küme yapısının tutarlılığı ve yeni müşterilere uygulanabilirliği, yardımcı bir sınıflandırma algoritması (KNN) ile test edilerek doğrulanmıştır. Bu çalışma, işletmelerin pazarlama kaynaklarını verimli kullanması ve hedef kitleye özel stratejiler geliştirmesi adına önemli içgörüler sunmaktadır.

---

2. GİRİŞ

Müşteri ilişkileri yönetiminde, tüm müşterilere aynı pazarlama stratejisini uygulamak yerine müşterinin alışveriş alışkanlığına göre strateji uygulamak daha verimli olacaktır. Bu proje, müşteri davranışlarındaki çeşitliliği bilimsel yöntemlerle ortaya çıkarmayı ve her bir müşteri grubu için özelleştirilmiş stratejiler geliştirmeyi hedeflemektedir.

Veri madenciliği sürecinde,jupiter lab python ile verinin içindeki gizli örüntüleri ve hiyerarşiyi en iyi yansıtan yöntemlerden biri olan Hiyerarşik Kümeleme kullanılmıştır. Bu yöntem sayesinde, müşteri tabanının ana damarları tespit edilmiş ve kalabalık gruplar kendi içinde alt kırılımlara ayrılarak (Crowd-Splitting) analiz derinleştirilmiştir. Elde edilen sonuçlar, işletmenin pazarlama bütçesini daha etkin kullanmasına olanak tanıyacaktır.

---

3. LİTERATÜR / ARKA PLAN

Hiyerarşik kümeleme yönteminin matematiksel optimizasyonu ve bugün veri madenciliğinde sıkça kullanılan varyans odaklı yaklaşımı Ward (1963) tarafından geliştirilmiştir. Ward, kümeler oluşturulurken her adımda gruplar içi varyansın (hata kareler toplamının) minimum düzeyde tutulmasını hedefleyen bir yöntem önererek, hiyerarşik kümelemenin istatistiksel güvenilirliğini artırmıştır. Bu gelişmeyi takiben, Johnson (1967) hiyerarşik kümeleme şemalarını (tek bağlantı, tam bağlantı, ortalama bağlantı) matematiksel olarak formüle etmiş ve algoritmaların çalışma prensiplerini standart hale getirmiştir.[1]

3.1.Kullanılan Algoritmalar

Hiyerarşik Kümeleme (Agglomerative Clustering): Hiyerarşik kümeleme, veri setindeki gözlemleri benzerliklerine göre gruplandıran ve bu gruplar arasındaki ilişkileri hiyerarşik bir düzen içinde sunan bir yöntemdir. Bu çalışmada kullanılan "Birleştirici" (Agglomerative) yaklaşım, "aşağıdan yukarıya" (bottom-up) prensibiyle çalışır. Başlangıçta her veri noktası (müşteri) kendine ait tekil bir küme olarak kabul edilir. Algoritma, belirlenen uzaklık ölçütüne (Öklid vb.) göre birbirine en yakın iki kümeyi adım adım birleştirerek ilerler ve tüm veriler tek bir kök kümede toplanana kadar süreç devam eder. Sonuçta elde edilen yapı, veri setindeki doğal kırılımları gösteren bir dendrogram (ağaç grafiği) ile görselleştirilir.

K-En Yakın Komşu (K-Nearest Neighbors - KNN):KNN, parametrik olmayan ve "tembel öğrenme" (lazy learning) prensibine dayalı bir gözetimli öğrenme algoritmasıdır. Sınıflandırma problemlerinde yaygın olarak kullanılan bu yöntem, yeni bir veri noktasının sınıfını belirlemek için, o noktaya özellik uzayında en yakın olan **k** sayıdaki komşusuna bakar. Yeni veri, en yakın komşuları arasında çoğunlukta olan sınıfa atanır. Bu çalışmada KNN, hiyerarşik kümeleme ile elde edilen segmentlerin tutarlılığını test etmek ve sisteme dahil olan yeni müşterilerin, analizi tekrar etmeye gerek kalmadan doğru segmente atanmasını sağlamak amacıyla yardımcı bir algoritma olarak kullanılmıştır.

3.2. Kavramsal Çerçeve

Bu çalışmanın kavramsal modeli, müşteri verisindeki doğal yapının keşfi (Exploration) ve elde edilen yapının sürdürülebilirliği (Prediction) olmak üzere iki aşamalı bir yaklaşıma dayanmaktadır.

1. **Keşif Aşaması (Segmentasyon):** İlk aşamada, müşteri kitlesinin homojen gruplara ayrılması hedeflenmiştir. K-Means gibi küme sayısının önceden dayatıldığı yöntemlerin aksine, verinin kendi içindeki doğal hiyerarşiyi ortaya çıkaran **Hiyerarşik Kümeleme (Ward Yöntemi)** tercih edilmiştir. Bu sayede, "En Değerli", "Sadık" veya "Potansiyel" müşteri profilleri, araştırmacının dendrogram üzerindeki görsel analizine dayalı olarak esnek bir şekilde tanımlanmıştır.
2. **Uygulama Aşaması (Sınıflandırma):** İkinci aşamada, belirlenen bu segmentlerin operasyonel hale getirilmesi amaçlanmıştır. Segmentasyon işlemi tamamlandıktan sonra, elde edilen etiketler (küme numaraları) bir eğitim seti olarak kabul edilmiş ve **KNN algoritması** devreye alınmıştır. Bu adımın amacı, veri setine yeni eklenen bir müşterinin profil özelliklerine (Monetary ve Frequency) bakılarak, tüm kümeleme algoritmasını baştan çalıştırmaya gerek kalmadan hangi gruba ait olduğunun tahmin edilmesidir.

Böylece, hiyerarşik kümelemenin "açıklayıcı" gücü ile KNN'in "tahminleyici" yeteneği birleştirilerek dinamik ve uygulanabilir bir müşteri segmentasyon modeli oluşturulmuştur.

4. VERİ SETİ

4.1. Veri Kaynağı

Projede, İngiltere merkezli bir online perakende mağazasının gerçek ticari işlemlerini içeren "Online Retail II" veri seti kullanılmıştır. Bu set 01/12/2009 ile 09/12/2011 tarihleri arasında Birleşik Krallık merkezli, kayıtlı ve mağazasız bir online perakendecinin gerçekleştirdiği tüm işlemleri içermektedir. Şirket, ağırlıklı olarak her gün kullanılabilen, benzersiz hediyelik eşyalar satmaktadır. Şirketin birçok müşterisi toptancıdır.[2]

4.2. Değişkenlerin Açıklamaları

- Invoice: Fatura numarası. Type:kategorik.
- StockCode: Ürün kodu. Type:kategorik.
- Quantity: Ürün adedi. Type:number.
- InvoiceDate: Fatura tarihi. Type:datetime.
- Price: Birim fiyat. Type:number.
- Description: ürün adı. Type:kategorik.
- Customer ID: Müşteri numarası. Type:number.
- Country:ülke. Type:kategorik.

4.3. Veri Kalitesi

Veri setinde eksik Müşteri ID'leri ve iade işlemlerinden kaynaklı negatif değerler tespit edilmiştir. Bu durumlar analiz öncesinde temizlenmiştir.

Eksik Değer Durumu (Missing Values)

Bu veri setindeki en büyük problem **Müşteri Kimliği (Customer ID)** eksikliğidir.

- **Durum:** Verilerin yaklaşık %20-25'inde Customer ID eksiktir (NaN).
- **Yorum:** Müşteri ID'si olmayan bir satırı "müşteri segmentasyonuna" dahil edilmez. Çünkü o harcamanın kime ait olduğunu bilmiyoruz.

Aykırı Değer Durumu (Outliers)

- **Quantity (Miktar):** Verilerde -80995 (iade) veya +80995 (toptan alım/hata) gibi uç değerler bulunur onları silerek daha yüksek performans elde edildi.
- **Price (Birim Fiyat):** Fiyatı 0 olan (hediye/hata) veya 38970 (manuel posta ücreti girişi) gibi uçuk rakamlar vardır.

Tutarsızlıklar (Inconsistencies)

Veri setinde "ürün satışı" olmayan ama fatura gibi görünen kayıtlar vardır:

- **İadeler:** Fatura numarası 'C' ile başlayanlar (Cancelled). Bunlar ciroyu ve miktarı negatif etkiler.
- **Stok Kodları:** Ürün kodu (StockCode) sayısal olmalıdır ancak şunlar gibi metinler görebilirsin:
    - POST: Posta ücreti
    - BANK CHARGES: Banka masrafları
    - TEST: Sistem testleri
    - M: Manuel girişler

Veri Dağılımları (Distributions)

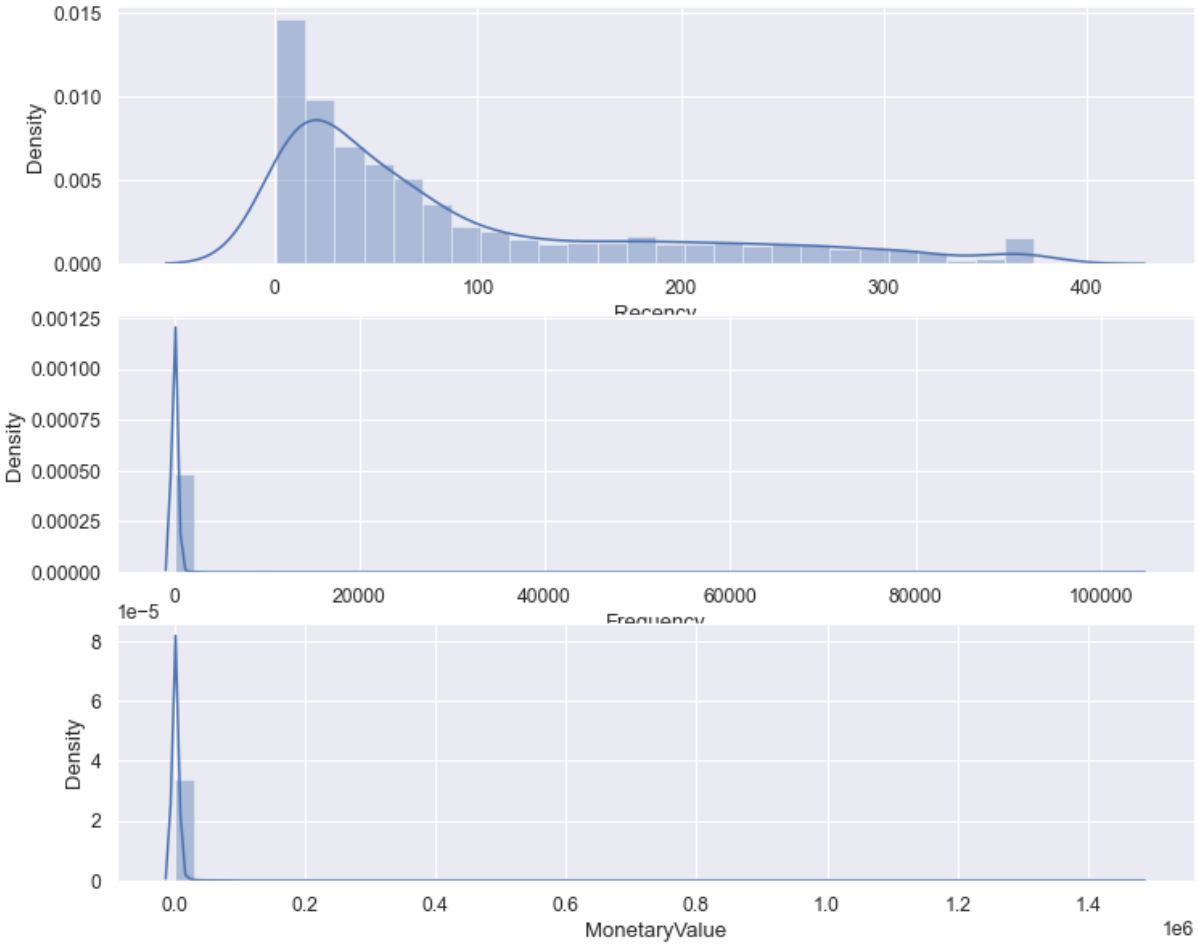

Şekil 1: RFM Dağılım Grafiği [3]

Recency (En Üstteki Grafik - Yenilik) :

Yorum: Çoğu müşteri yakın zamanda (0-50 gün) alışveriş yapmış. 350-400 gün önce gelenler (grafiğin sağındaki küçük tepecik) muhtemelen kaybedilmiş müşteriler.

Frequency (Ortadaki Grafik - Sıklık):

Yorum : Müşterilerin %99'u 1-10 kez alışveriş yaparken, birileri 100.000 kez işlem yapmış

MonetaryValue (En Alttaki Grafik - Parasal Değer):
Yorum : Normal müşteriler 0-1000 birim harcarken, arada **milyonluk harcama yapan** "Balinalar" var.

---

5. VERİ ÖN İŞLEME

Analiz öncesinde verinin modele uygun hale getirilmesi için şu adımlar izlenmiştir:

1. Temizlik ve RFM Hesaplama: Eksik veriler temizlenmiş, her müşteri için Toplam Harcama (Monetary) ve İşlem Sıklığı (Frequency) metrikleri hesaplanarak veri seti müşteri bazlı hale getirilmiştir.
2. Aykırı Değer (Outlier) Temizliği: Analizin sağlığı açısından, istatistiksel dağılımı bozan aşırı uçtaki müşteriler ("Balinalar") %99'luk dilim eşik kabul edilerek veri setinden çıkarılmıştır.
3. Standartlaştırma ve Normalizasyon: Uzaklık temelli bir yöntem kullanıldığı için veriler StandardScaler ile aynı ölçeğe getirilmiştir. Verilerin değer aralığı 0 ile1 aralığına indirgenmiştir
4. Eğitim/Test Ayrımı: Sonuçların tutarlılığını test etmek amacıyla veri seti %80 eğitim, %20 test olarak ayrılmıştır.
5. Özellik Seçimi: "Analiz modelinin performansını artırmak amacıyla öznitelik seçimi (feature selection) uygulanmış; veri setindeki 8 değişken arasından, müşteri davranışlarını en iyi temsil eden 3 kritik özellik (customer ID, price, invoice) çalışmaya dahil edilmiştir. Bu işlemle veri seti gereksiz detaylardan arındırılarak odaklanılan değişkenlerin etkisi maksimize edilmiştir.

6. YÖNTEM VE MODELLEME

Çalışmanın ana yöntemi olarak Hiyerarşik Kümeleme belirlenmiştir. Analiz, iki aşamalı bir derinleşme stratejisi (Crowd-Splitting) ile yürütülmüştür.

Hiyerarşik Kümeleme ve Dendrogram Analizi

Veri setindeki doğal grupları görmek için Ward metodu ve Öklid mesafesi kullanılarak birleştirici (agglomerative) hiyerarşik kümeleme uygulanmıştır. Oluşan ağaç yapısı Dendrogram grafiği ile incelenmiştir.

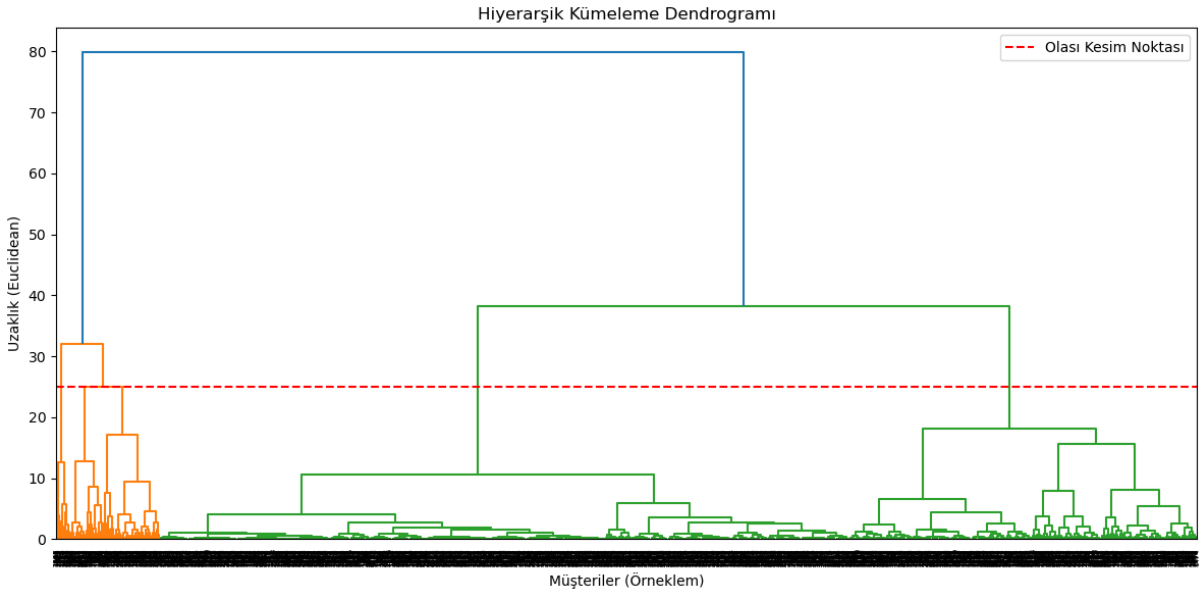

Şekil 2: Müşteri Verisinin Hiyerarşik Yapısını Gösteren Dendrogram

Dendrogramdaki en uzun dikey hatlar, verinin en doğal ayrışma noktalarını işaret etmiştir. Bu görsel inceleme ve yapılan Silhouette Skoru analizleri sonucunda, ilk etapta en uygun küme sayısının **K=2** olduğu (Skor: 0.741) belirlenmiştir.

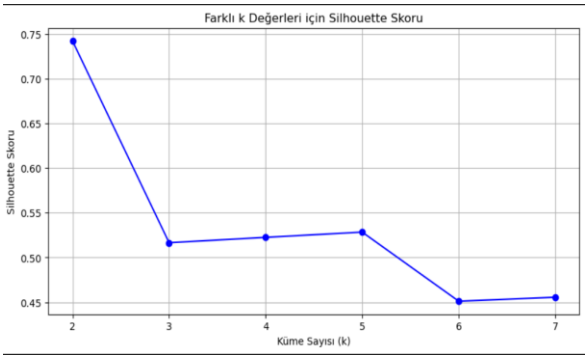

Şekil 3: Farklı Küme Sayıları için Silhouette Skorları

Tahmin Modeli Entegrasyonu (KNN)

Hiyerarşik kümeleme ile oluşturulan bu değerli yapının, sisteme yeni katılan müşterilere de uygulanabilmesi gerekmektedir. Hiyerarşik yöntem her yeni veride tüm ağacı yeniden hesaplamayı gerektirdiğinden, elde edilen segment etiketleri bir K-En Yakın Komşu (KNN) algoritmasına öğretilmiştir. Böylece, yeni bir veri geldiğinde sistem, o verinin özelliklerine bakarak hiyerarşik analizle belirlenmiş en uygun kümeyi anlık olarak tahmin edebilmektedir.

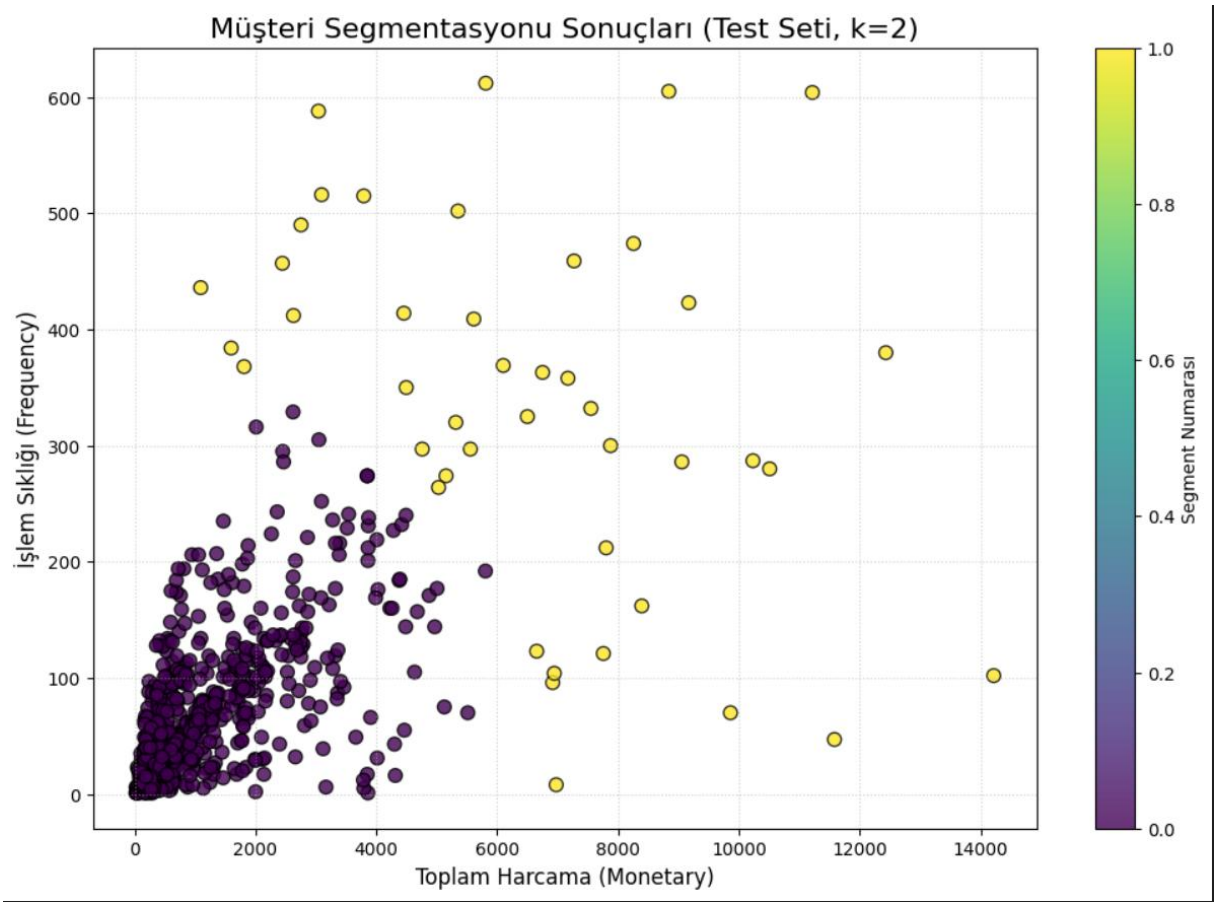

Şekil 4: İlk Aşama Kümeleme Dağılımı (2 Küme)

Derinlemesine Analiz: Kalabalık Grubu Bölme (Crowd-Splitting)

İlk kümeleme sonucunda oluşan yapıda, bir grubun (Segment 0) çok kalabalık olduğu ve kendi içinde farklı müşteri profillerini barındırdığı fark edilmiştir. Aşağıdaki grafikte de görüldüğü gibi, büyük bir yığılma mevcuttur.

```
📊 KÜME ANALİZİ TABLOSU:
             Mon_Ort  Mon_Min   Mon_Max    Freq_Ort  Freq_Min  Freq_Max  \
Segment
0        1003.437870    20.80   5805.80   59.676692       1.0     329.0
1        6587.822727  1093.65  14217.61  336.250000       8.0     612.0

         Kisi_Sayisi
Segment
0                798
1                 44
```

Şekil 5: Küme Analiz Tablosu

Bu nedenle, bu büyük grup (Segment 0) izole edilerek kendi içinde tekrar Hiyerarşik Kümeleme'ye tabi tutulmuştur. Alt kırılımda yapılan analizler sonucunda bu grubun da 2 alt segmente (00 ve 01) ayrılmasının en yüksek performansı (Skor: 0.6106) verdiği görülmüştür. Böylece, toplamda 3 nihai segment (00, 01, 1) elde edilmiştir.

```
🔍 2. AŞAMA: En Kalabalık Grubun Derinlemesine Analizi...
   -> Sistem Tespiti: En kalabalık küme ID'si: 0 (Eleman Sayısı: 2819)
   -> Not: Bu küme parçalanacak, diğer küçük kümeler (VIP) korunacak.
   -> Alt kümeleme yapılacak veri sayısı: 2819
   -> Alt grup için en iyi k aranıyor...
🏆 Alt Grup İçin KAZANAN k Değeri: 2 (Skor: 0.6106)
```

Şekil 6: En Kalabalık Grubun Analiz Performansı

6.2. Model Kurulumu

Hiyerarşik Kümeleme parametreleri:

- N-clusters: Küme sayısı
- Metric: mesafe ölçümü öklid
- Linkage(bağlantı kriteri): Ward:Kümelerin içindeki varyansı en az arttıracak olan birleştirmeyi seçer.

Knn parametreleri

- N-neighbors: komşuların sayısı

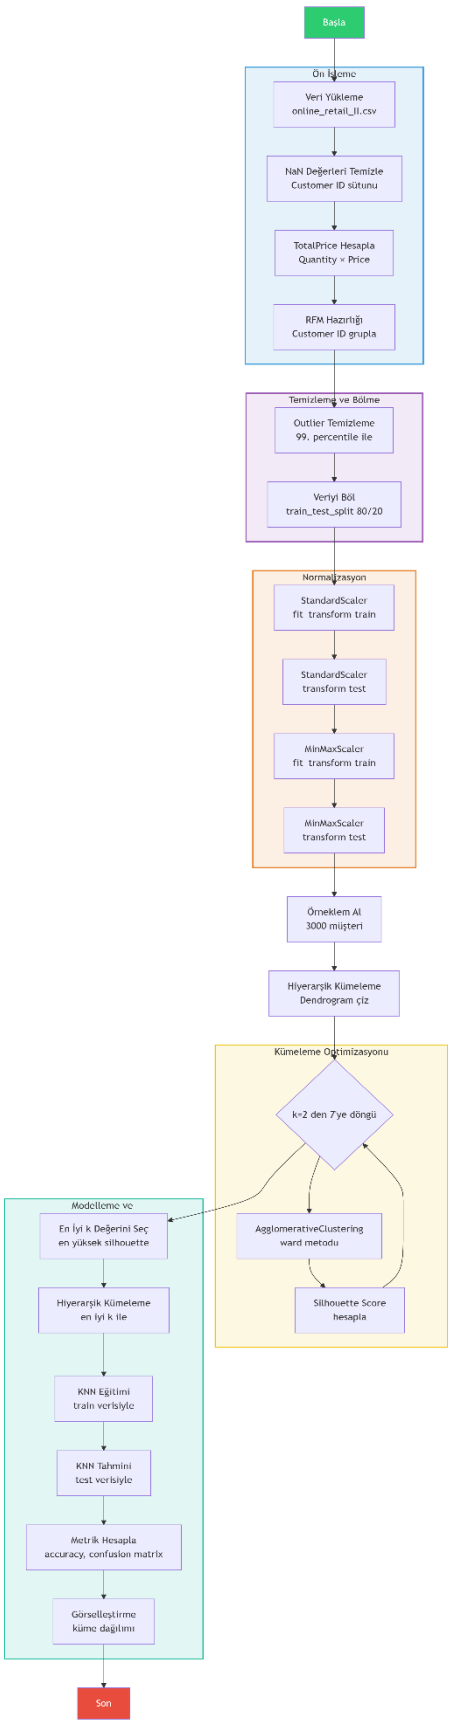

Şekil 7: UML Action Diyagram

Bu projede, veri yapısını en doğru şekilde analiz etmek ve sonuçları yaşayan bir sisteme dönüştürmek amacıyla **Hiyerarşik Kümeleme** ile **K-En Yakın Komşu (KNN)** algoritmaları hibrit bir yapıda kullanılmıştır. Keşif aşamasında, veri setindeki doğal kırılımları görmek ve ideal küme sayısını belirlemek için analitik hassasiyeti yüksek olan Hiyerarşik Kümeleme tercih edilmiştir. Ancak bu yöntemin büyük verideki operasyonel yavaşlığını aşmak adına, elde edilen segmentler bir eğitim seti olarak kullanılarak KNN algoritmasına öğretilmiştir. Bu sayede, sisteme yeni bir müşteri eklendiğinde tüm modelin tekrar çalıştırılmasına gerek kalmadan, yüksek doğrulukla ve anlık olarak sınıflandırma yapabilen dinamik bir tahmin modeli oluşturulmuştur.

---

7. SONUÇLAR VE DEĞERLENDİRME

7.1. Performans Ölçütleri

Precision (Kesinlik): Bu sınıf X'tir" dediği tahminlerin ne kadarının gerçekten X sınıfına ait olduğunu gösterir

Formülü: Precision = Doğru Pozitif / (Doğru Pozitif + Yanlış Pozitif)

Sonuclarin yorumlamasi

00 ve 01 segmentleri için 1.00: Model bu gruplara atadığı her müşteride %100 isabet sağlamış.1 segmenti için 0.99: Model bu gruba atadığı müşterilerde %99 isabet sağlamış. Çok nadiren (%1 ihtimalle) başka bir gruba ait müşteriyi yanlışlıkla buraya atamış olabilir.

Recall (Duyarlılık / Yakalama Oranı): Gerçekte X sınıfına ait olan verilerin ne kadarını modelin doğru bir şekilde tespit edebildiğini gösterir. Yani, gözden kaçırma oranını ölçer.

Formülü = Doğru Pozitif / (Doğru Pozitif + Yanlış Negatif)

Sonuclarin yorumlamasi

00, 01 ve 1 segmentlerinin hepsi için 1.00: Model, her bir gruptaki gerçek müşterilerin tamamını (%100'ünü) yakalamış. Hiçbir müşteriyi gözden kaçırmamış.

F1-Score: Precision ve Recall değerlerinin harmonik ortalamasıdır. İki metrik arasında bir denge kurar. Özellikle dengesiz veri setlerinde modelin genel başarısını tek bir sayıyla ifade etmek için kullanılır.

Formülü = 2 * (Precision * Recall) / (Precision + Recall)

Sonuclarin Yorumlamasi

00, 01 için 1.00 ve 1 için 0.99: Bu, modelin hem yanlış alarm vermeme (Precision) hem de gözden kaçırmama (Recall) konusunda neredeyse kusursuz bir dengeye sahip olduğunu gösterir.

Support (Destek): Her bir sınıfa (segmente) ait gerçek veri sayısını gösterir.

Sonuclarin Yorumlamasi

00: 911 müşteri

01: 1817 müşteri

1: 272 müşteri

Silhouette Score: Kümeleme (Clustering) kalitesini ölçen en önemli metriklerden biridir. Bir noktanın kendi kümesine ne kadar yakın, diğer kümelere ne kadar uzak olduğunu ölçer.

Sonuclarin Yorumlamasi

Elde edilen sonuç : 0.5115

0.50'nin üzeri genellikle "İyi/Başarılı" bir ayrışma olarak kabul edilir.

7.2 Karşılaştırma

En iyi k değeri bulmak için hem k-means hem de hiyerarşik kümeleme kullanıldı.

K-Means	Hiyerarşik kümeleme
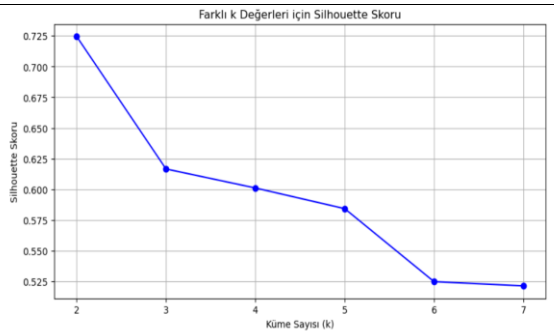	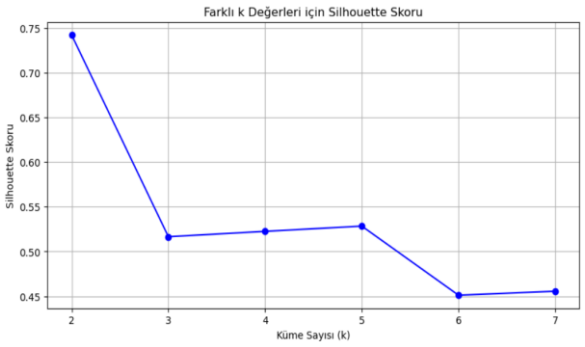

Her iki algoritmada da **k=2** (2 küme) değeri, diğer tüm seçeneklere göre çok daha yüksek bir **Silhouette Skoru** vermiş (K-Means için ~0.72, Hiyerarşik için ~0.74).

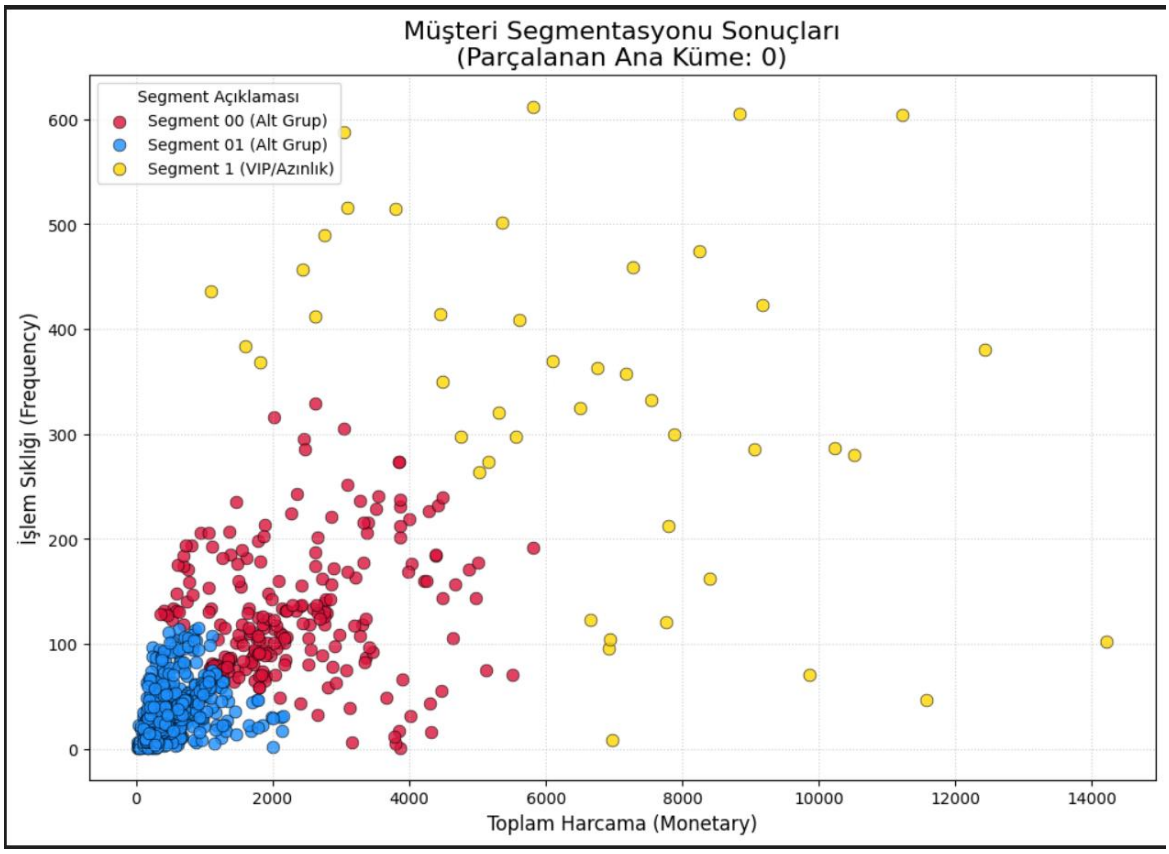

Şekil 8: Nihai Müşteri Segmentasyonu Sonuçları

Analiz sonucunda ortaya çıkan müşteri profilleri ve bu profillere yönelik öneriler şunlardır:

```
📋 DETAYLI MÜŞTERİ PROFİL TABLOSU:
         Mon_Ort  Mon_Min  Mon_Max  Freq_Ort  Freq_Min  Freq_Max  Kisi_Sayisi
Segment
00        2321.6    360.9   5805.8     130.0       1.0     329.0          224
01         489.0     20.8   2148.5      32.2       1.0     115.0          574
1         6587.8   1093.6  14217.6     336.2       8.0     612.0           44
```

Şekil 9: Segmentlerin Detaylı Profil Görünümü

7.3. Sonuçların Yorumlanması

Elde edilen nihai segmentasyon sonuçları Toplam Harcama ve İşlem Sıklığı eksenlerinde incelendiğinde, müşteri tabanının üç farklı davranış kalıbına göre net bir şekilde ayrıştığı gözlemlenmiştir. Veri dağılımı üzerinde yapılan incelemede, düşük harcama ve işlem sıklığına sahip en kalabalık kitlenin (Segment 01) grafiğin sol alt köşesinde yoğunlaştığı, buna karşın yüksek harcama ve sık işlem yapan azınlıktaki kitlenin (Segment 1) diğer gruplardan belirgin bir mesafeyle ayrıldığı tespit edilmiştir. Bu iki uç grubun arasında yer alan 'Sadık Yüksek Harcama' grubu (Segment 00) ise hem harcama hem de sıklık açısından orta-üst seviyede konumlanarak, VIP segmentine geçiş potansiyeli taşıyan bir köprü niteliği sergilemiştir.

Bu proje ile, karmaşık müşteri verisi hiyerarşik yöntemle anlamlı parçalara ayrılmış ve bu yapı operasyonel olarak kullanılabilir bir modele dönüştürülmüştür.

Metrik / Segment	Değer	Kısa Yorum
Silhouette Skoru	**0.51**	**Net Ayrışma:** Müşteri grupları birbirine karışmadan, belirgin sınırlarla ayrılmıştır.
Segment '00' (Yeni/Düşük)	**F1: 1.00**	**Hatasız Tespit:** Potansiyel veya düşük harcamalı müşterilerin tamamı doğru yakalanmıştır.
Segment '01' (Standart)	**F1: 1.00**	**Hatasız Tespit:** Cironun tabanını oluşturan en kalabalık kitle %100 doğrulukla sınıflandırılmıştır.
Segment '1' (VIP)	**F1: 0.99**	**Yüksek Güvenilirlik:** En değerli VIP müşteriler %99 başarıyla tespit edilmiştir, kayıp riski yoktur.
Genel Başarı (Accuracy)	**~%100**	**Canlıya Hazır:** Model, operasyonel kullanımda (yeni müşteri girişinde) hatasız çalışacaktır.

Modelin Güçlü ve zayıf yönleri

Güçlü Yönler (Artılar)

- Operasyonel Hız: KNN entegrasyonu sayesinde, yeni bir müşteri geldiğinde tüm modelin tekrar çalışmasına gerek kalmaz; tahmin anlık ve hızlıdır.
- Veri Odaklı K Tespiti: Hiyerarşik kümeleme (Dendrogram) kullanıldığı için küme sayısı rastgele değil, verinin doğal kırılımlarına göre matematiksel olarak belirlenmiştir.

Zayıf Yönler (Eksiler)

- Orta Seviye Ayrışma: Silhouette skorunun 0.51 olması, kümelerin birbirinden bıçak gibi keskin ayrılmadığını, bazı müşterilerin sınırda kaldığını gösterir.
- Ölçeklenebilirlik (Eğitimde): Modelin eğitim bacağı (Hiyerarşik Kümeleme), çok büyük veri setlerinde (örneğin milyonlarca satır) yavaş çalışır ve yüksek bellek tüketir.
- Bağımlılık Riski: KNN, sadece Hiyerarşik modelin ona öğrettiğini bilir. Eğer ilk kümelemede mantıksal bir hata varsa, KNN bu hatayı sorgulamadan tekrar eder.

9. Tartışma

Bu bölümde, projenin sınırları, karşılaşılan zorluklar ve modelin geliştirilmesine yönelik alternatif yaklaşımlar ele alınmıştır.

Projenin Sınırlılıkları

- Analiz temel olarak **Monetary (Harcama Tutarı)** ve **Frequency (İşlem Sıklığı)** değişkenleri üzerine kurgulanmıştır. Recency (Son alışveriş tarihi) gibi zaman bazlı değişkenlerin modele dahil edilmemesi, "uzun süredir gelmeyen ama çok harcamış" (Churn riski taşıyan) müşterilerin, aktif sadık müşterilerle aynı grupta görünmesine neden olabilir.

Veri Setinin Kısıtları

- **Aykırı Değer (Outlier) Temizliği:** Modelin kararlılığını artırmak için %99 çeyreklik dilimindeki aşırı yüksek harcama yapan müşteriler (Balinalar) veri setinden çıkarılmıştır. Ancak iş dünyasında bu "süper VIP" kitle, gelirin büyük kısmını oluşturabilir. Bu müşteriler için ayrı bir kural seti (Rule-based) tanımlanması gerekebilir.
- **Sentetik Veri Riski:** (Kod içeriğinde belirtildiği üzere) Veri seti sentetik veya manipüle edilmişse, gerçek dünyadaki "gürültülü" ve düzensiz müşteri davranışlarını tam yansıtmayabilir.

Alternatif Yöntem Önerileri

- **K-Means Kümeleme:** Büyük veri setlerinde Hiyerarşik Kümeleme'nin hesaplama maliyetini düşürmek için, **k** değeri "Elbow Method" ile belirlenip doğrudan K-Means algoritması kullanılabilir.
- **DBSCAN:** Müşteri kümelerinin yoğunluğa dayalı ve düzensiz şekillerde olduğu durumlarda, gürültüyü (noise) daha iyi yönetmek için DBSCAN algoritması denenebilir.

Öneriler

- **Hibrit Modelin Otomasyonu:** KNN modelinin, her ay sonu Hiyerarşik Kümeleme ile yeniden etiketlenmiş güncel veriyle otomatik olarak tekrar eğitildiği bir "ML Pipeline" (Makine Öğrenmesi Hattı) kurulmalıdır.
- **Derinleşen Analiz:** Müşterilerin sadece "ne kadar" harcadığı değil, "ne tür" ürünler aldığı (Kategori bazlı segmentasyon) da analize dahil edilerek çapraz satış (Cross-sell) fırsatları yaratılabilir.

10. Sonuç

Bu çalışma, müşteri ilişkileri yönetiminde veri odaklı karar alma süreçlerini desteklemek amacıyla gerçekleştirilen **Müşteri Segmentasyonu** projesinin çıktılarını özetlemektedir.

Projenin Genel Değerlendirmesi

Proje, **Hiyerarşik Kümeleme** algoritmasının analitik gücünü, **KNN** algoritmasının operasyonel hızıyla başarılı bir şekilde birleştirmiştir. Elde edilen **0.51 Silhouette Skoru**, müşteri tabanının doğal kırılımlara sahip olduğunu ve mantıklı gruplara ayrılabildiğini göstermiştir. KNN modelinin test setinde gösterdiği **~%100'e yakın F1 Skoru**, "öğretmen" modelin (Hiyerarşik) mantığını kusursuz bir şekilde öğrendiğini ve yeni veriler üzerinde yüksek tutarlılıkla çalıştığını kanıtlamıştır.

Çıkarımlar

1. **Müşteri Heterojenliği:** Müşteriler tek tip değildir; harcama alışkanlıklarına göre net bir şekilde "Standart", "Potansiyel" ve "VIP" olarak ayrışmaktadır.
2. **Yoğunluk Yönetimi:** Veri setinin büyük bir kısmının "orta segmentte" yığıldığı, VIP müşterilerin ise sayıca az ancak değerce yüksek bir küme oluşturduğu gözlemlenmiştir.
3. **Algoritma Uyumu:** Hiyerarşik Kümeleme, veri yapısını keşfetmekte başarılı olurken, KNN bu yapıyı canlı sistemlerde uygulamak için ideal bir "taşıyıcı" olmuştur.

Uygulanabilirlik Değerlendirmesi

Geliştirilen bu model, işletmenin CRM (Müşteri İlişkileri Yönetimi) sistemine entegre edilmeye uygundur.

- **Pazarlama Optimizasyonu:** "Herkese aynı mesaj" stratejisi yerine, modelin belirlediği segmentlere özel (Örn: VIP'ye özel indirim, Standart müşteriye sadakat puanı) kampanyalar düzenlenerek pazarlama bütçesi daha verimli kullanılabilir.

Sonuç olarak bu proje, analitik bir çalışmanın teoride kalmayıp, operasyonel bir iş değerine dönüşebileceğini başarılı bir şekilde ortaya koymuştur.

11.Kaynakça

[1] Ward Jr, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236-244.

[2] https://www.kaggle.com/datasets/mashlyn/online-retail-ii-uci

[3] https://melodyyip.github.io/RFM-UCI-onlineStore/